

Offen im Denken

Institut für Informatik und Wirtschaftsinformatik (ICB)
Lehrstuhl für Software Engineering, insb. mobile Anwendungen
Prof. Dr. Volker Gruhn

Natural Language Processing zur Verbesserung von Suchfunktionen in der Software-Entwicklung

Bachelorarbeit

vorgelegt der Fakultät für Wirtschaftswissenschaften
der Universität Duisburg-Essen (Campus Essen) von

Leon Zimmermann
Laddringsweg 8
45219 Essen
Matrikelnummer: 3080384

Essen, den 19. April 2023

Betreuung:
Erstgutachter:
Zweitgutachter:

Wilhelm Koop, Sascha Feldmann
Prof. Dr. Volker Gruhn
???

Studiengang:
Semester:

Angewandte Informatik - Systems Engineering (B. Sc.)
10

Abstract

TODO

Zusammenfassung

TODO

Inhaltsverzeichnis

1. Einleitung	1
1.1. Motivation	1
1.2. Ziele der Arbeit	1
1.3. Vorgehensweise	2
1.4. Verwandte Arbeiten	2
1.5. Abgrenzungen	2
2. Auswahl von Use-Cases	3
2.1. Wahl des Abstraktionslevels	3
2.2. Semantik der Suche verstehen	3
2.3. Aktualität und Relevanz des Dokuments	3
3. Evaluationsmethoden und -Kriterien	4
3.1. Features	4
3.2. Qualitätskriterien	5
3.3. Precision, Recall und F-Maß	5
3.4. Befragungen	6
4. Arten von Suchfunktionen	7
4.1. Keyword Search	7
4.2. Phrase Search	7
4.3. Boolean Search	7
4.4. Structured Search	7
4.5. Lexical Search	8
4.6. Semantic Search	8
5. Vergleich der Suchfunktionen	10
6. Erläuterung des Ergebnisses	11
7. Implementierung	12
7.1. Crawling	12
7.2. Indizierung	12
7.3. Suffix-Trees	14
7.4. N-Gramm	14
7.5. Information Extraction	14
8. Zusammenfassung und Ausblick	16
8.1. Zusammenfassung	16
8.2. Ausblick	16

A. Anhang	18
A.1. TODO	18

Abbildungsverzeichnis

Tabellenverzeichnis

Abkürzungsverzeichnis

NLP Natural Language Processing

1. Einleitung

1.1. Motivation

Suchfunktionen sind in vielen Anwendungen vorhanden und können einen großen Einfluss auf die Erfahrung von Nutzern haben. Google ist ein Anbieter einer bekannten Suchfunktion. Sie wird verwendet, um im World Wide Web die passende Website für eine Suchanfrage zu finden. Die Suchanfrage besteht dabei meistens aus lediglich ein bis drei Keywords. Es ist nicht einfach für diese Keywords die Websites zu identifizieren, welche für einen Nutzer am passendsten ist. Auch andere Arten von Anwendungen verwenden Suchfunktionen, darunter Wissensdatenbanken, wie beispielsweise Confluence. In Wissensdatenbanken werden Informationen auf Seiten gespeichert, welche über die Suchfunktion auffindbar sein sollen. Softwareentwickler haben bei der Arbeit mit Wissensdatenbanken, insbesondere bei der Arbeit mit Spezifikationen und Dokumentationen, oft das Problem, dass die gesuchten Inhalte nicht gefunden werden können. Das kann daran liegen, dass die gefundenen Ergebnisse zu spezifisch sind, z.B. wenn eine allgemeine Definition von Domänenobjekten gesucht wird, aber eine Spezifikation eines Use-Cases gefunden wird, in welchem das Domänenobjekt lediglich erwähnt wird. Außerdem haben manche Wissensdatenbanken Schwierigkeiten, die Semantik einer Suchanfrage zu verstehen. Wird also nach einem Suchbegriff, wie „deployment“ gesucht, dann werden keine Ergebnisse gefunden, welche Wörter, wie „rollout“ beinhalten, auch wenn es sich hierbei um den gleichen Prozess handelt. Softwareentwickler müssen also das genaue Wording in der Dokumentation kennen, um ein sinnvolles Ergebnis angezeigt zu bekommen, und es reicht nicht aus, ein Synonym oder verwandte Wörter oder Konzepte in die Suche einzugeben. Weiterhin werden oftmals Inhalte angezeigt, welche bereits als deprecated markiert sind, und für aktuelle Versionen der Software keine Relevanz mehr haben. Ziel dieser Arbeit soll es sein, mithilfe von Wissen über Suchalgorithmen und Algorithmen aus dem Natural Language Processing, diese Probleme zu lösen, sodass Softwareentwickler in Zukunft besser die Inhalte finden, nach denen sie tatsächlich gesucht haben.

1.2. Ziele der Arbeit

TODO

Zur Erreichung des Hauptziels der Arbeit werden folgende Teilziele definiert:

- **Teilziel 1:** TODO
- **Teilziel 2:** TODO
- **Teilziel 3:** TODO

- **Teilziel 4:** TODO

1.3. Vorgehensweise

In der Problemstellung wurde behauptet, dass oftmals nicht die Inhalte gefunden werden, welche ein Softwareentwickler bei der Eingabe einer Suche erwarten würde. Diese Behauptung muss zunächst belegt werden. Dazu muss klar sein, welche Informationen ein Softwareentwickler sucht, wenn er die Suchfunktion einer Wissensdatenbank verwendet. Diese sollen in Form von Use-Cases beschrieben werden. Außerdem werden Methoden und Metriken zur Evaluation von Suchfunktionen erläutert. Und es werden verschiedene Implementierungen von Suchfunktionen aufgezählt und kurz beschrieben. Diese verschiedenen Suchfunktionen werden nun für die ausgewählten Use-Cases anhand der zuvor beschriebenen Metriken evaluiert. Um den Rahmen dieser Arbeit nicht zu sprengen, sollen lediglich zwei verschiedene Suchfunktionen miteinander verglichen werden. Zuletzt wird die Implementierung der Suchfunktion erläutert, welche besser abgeschnitten hat.

Adressierung von Teilziel 1

TODO

Adressierung von Teilziel 2

TODO

Adressierung von Teilziel 3

TODO

Adressierung von Teilziel 4

TODO

1.4. Verwandte Arbeiten

- Elasticsearch: <https://www.elastic.co/de/> • Apache Lucene: <https://lucene.apache.org>
- TODO

1.5. Abgrenzungen

Diese Arbeit behandelt keine Large Language Models, wie GPT.

2. Auswahl von Use-Cases

2.1. Wahl des Abstraktionslevels

Oft ist im Voraus nicht klar, was man genau sucht. Man gibt einen Suchbegriff ein und möchte "sinnvolle" Informationen zu diesem Suchbegriff bekommen. Sinnvoll könnte eine Definition des Begriffs sein, oder ein Überblick darüber, in welchen Bereichen und Kontexten dieser Begriff vorkommt.

TODO

2.2. Semantik der Suche verstehen

TODO

2.3. Aktualität und Relevanz des Dokuments

Manchmal werden Blog-Einträge von unbekannten Benutzern angezeigt, welche sehr kurz sind. Die Überschrift ist zwar passend, aber der Inhalt des Textes nicht. Und der Text ist nur sehr kurz. Es scheint offensichtlich, dass für allgemeine Suchanfragen längere Texte als Ergebnis sinnvoller sind, da eine allgemeine Suchanfrage der Versuch ist, sich mit einem Thema vertraut zu machen. In diesem Fall sollten viele Informationen priorisiert werden, gegenüber kurzen Texten, welche die Lösung eines sehr spezifischen Problems erläutern.

Manchmal werden alte Seiten gefunden oder unfertige Seite. Es sollte erkannt werden, wenn eine Seite veraltet ist (ist markiert), oder wenn sie noch nicht fertig ist (durch Markierung oder Länge/Struktur des Textes)

TODO

3. Evaluationsmethoden und -Kriterien

3.1. Features

Relevanz

Eine Suchfunktion muss nicht nur Ergebnisse für eine Such-Query finden, sondern diese auch darstellen. Bei der Darstellung der Ergebnisse ist die Reihenfolge besonders wichtig. Manchmal hat der Nutzer keine genaue Vorstellung davon, was genau er sucht. Er möchte Informationen zu einem Thema finden, aber ohne dabei bestimmte Seiten oder Inhalte im Hinterkopf zu haben. Nichtsdestotrotz möchte der Nutzer mit minimalem Aufwand so viele wichtige Informationen, wie möglich erhalten. Die Sortierung von Ergebnissen der Suche soll genau das ermöglichen. Nun ist zu klären, wie die Bestimmung der Relevanz von Suchergebnissen überhaupt funktioniert. Es muss bestimmt werden, anhand welcher Kriterien die Suchfunktion die Relevanz bestimmt. Für diese Kriterien gibt es wiederum unterschiedliche Quellen. Eine Quelle für Kriterien der Relevanz ist das Nutzerverhalten. Seiten, die besonders häufig besucht werden und auf denen lange verweilt wird, oder welche sehr häufig bearbeitet werden, sind gute Kandidaten für eine hohe Relevanz. Seiten, welche bei Nutzern praktisch in Vergessenheit geraten sind, scheinen nicht so wichtig zu sein, sodass die Relevanz für die Suche niedrig ist.

Clustering

Thematisch ähnliche Dokumente tendieren dazu relevant für die gleiche Suche zu sein. Aus diesem Grund ist es oftmals sinnvoll ähnliche Dokumente zu clustern, also zu gruppieren, und sie dem Nutzer als ein solches Cluster darzustellen. Alternativ kann auch ein Suchergebnis dargestellt werden und ähnliche Suchergebnisse werden angezeigt als „Ähnliche Suchergebnisse“.

Autovervollständigung

Autovervollständigung bedeutet, dass während der Eingabe von Suchbegriffen bereits Ergänzungen für die gesamte Eingabe vorgeschlagen werden. Das ist vor allem ein hilfreiches Feature in Fällen, wo der Nutzer nur eine grobe Ahnung davon hat, was er eigentlich sucht. Mithilfe von Vorschlägen durch die Suchmaschine selbst kann der Nutzer seine Eingabe spezifischer fassen als er es ohne Vorschläge schaffen würde, sodass die Suchergebnisse besser zu dem passen, was er eigentlich sucht.

Best-Prefix-Highlighting

Das ähnlichste Ergebnis zur Eingabe des Nutzers soll gehighlightet werden.

Synonyme

Synonyme bei Suche mitbeachten.

3.2. Qualitätskriterien

Interaktivität

Klassische Suchfunktionen sind so konzipiert, dass der Nutzer einen Suchbegriff eingibt, anschließend auf einen Submit-Button klickt und erst dann Suchergebnisse angezeigt bekommt. Der Nachteil dieser Vorgehensweise ist, dass der Nutzer erst spät Feedback darüber bekommt, ob er mit den eingegebenen Suchbegriffen auch Ergebnisse bekommt, die für ihn gerade sinnvoll sind. Das Qualitätskriterium Interaktivität gibt an, wie kurz die Zeit zwischen dem Eingeben von Suchbegriffen und der Anzeige von Ergebnissen ist. Eine Suchfunktion muss nicht unbedingt einen Submit-Button verwenden. Die Suche kann auch mit jedem ausgeschriebenen Keyword die Suche starten und Ergebnisse dafür anzeigen, oder auch nach jedem eingegebenen Buchstaben. Mit einer kürzeren Zeit zwischen Eingabe und Ergebnis, also einer höheren Interaktivität, weiß der Nutzer schneller, ob seine Eingaben sinnvoll sind, und bekommt damit schneller gute Suchergebnisse.

Geschwindigkeit

Die Geschwindigkeit einer Eingabe ist die Zeit zwischen dem Beginn der Suche und der Anzeige der ersten Antwort. Die Geschwindigkeit hat nichts mit der Interaktivität zu tun.

Darstellung

Wie gut kann man anhand der Zusammenfassung der Ergebnisse den Inhalt bestimmen.

Benutzerfreundlichkeit

Das System findet auch Ergebnisse für ähnliche Wörter. So sind bspw. Tippfehler kein Problem. Fuzzy-Search.

3.3. Precision, Recall und F-Maß

Zur Evaluation werden die Werte Precision und Recall gemessen. Der Precision-Wert ist das Verhältnis zwischen allen gefundenen Dokumenten und den gefundenen Dokumenten, die tatsächlich relevant sind. Der Recall-Wert gibt an, wie

viele von den tatsächlich relevanten Dokumenten auch gefunden wurden. Es ist schwierig beide Werte zu optimieren, da der Precision-Wert versucht die Anzahl der gefundenen Dokumente einzugrenzen und der Recall-Wert versucht die Anzahl der gefundenen Dokumente zu erweitern. Das F-Maß fasst beide Werte zu einem neuen Wert zusammen.

3.4. Befragungen

TODO

4. Arten von Suchfunktionen

4.1. Keyword Search

TODO

4.2. Phrase Search

Eine Phrase Search ist die Suche nach Textausschnitten in Dokumenten. Es werden also nicht mehrere Keywords einzeln betrachtet, sondern die Eingabe in das Suchfeld als Ganzen. Anschließend wird in Dokumenten nach genau diesem Textausschnitt gesucht.

4.3. Boolean Search

TODO

4.4. Structured Search

Eine klassische Suchfunktion verwendet Keywords, um relevante Dokumente für eine Sucheingabe zu ermitteln. Der Vorteil dieser Art von Suche ist, dass die technische Struktur, in der die Daten vorliegen und gespeichert sind, nicht bekannt sein müssen. Der Nachteil ist auf der anderen Seite, dass die Suchergebnisse unpräzise sein können. Wenn beispielsweise der Suchbegriff Kamera eingegeben wird, dann werden Kameras als Ergebnisse zurückgegeben. Soll die Kamera nun bestimmte Eigenschaften besitzen, dann müssen diese Eigenschaften ebenfalls als Keywords angegeben werden. Nun wird aber nicht die Suche auf Ergebnisse eingegrenzt, bei denen eine Kamera diese bestimmten Eigenschaften besitzt. Stattdessen werden Suchergebnisse angezeigt, bei denen einige dieser Keywords vorkommen. Demgegenüber stehen Datenbankabfragen, beispielsweise mithilfe von SQL. Bei einer Datenbankabfrage können Objekte abgefragt werden, dessen Eigenschaften ganz bestimmte Werte haben. Die Ergebnisse, die eine solche Abfrage zurückgibt, sind dabei vollkommen genau. Es werden keine Objekte zurückgegeben, welche diese Kriterien nicht erfüllen. Voraussetzung für eine solche Suchabfrage ist allerdings, dass die Struktur der Datenbank a priori bekannt ist. Dem Nutzer muss der Name der Datenbank, der relevanten Tabellen, sowie der relevanten Properties bekannt sein, damit er das passende SQL für die Datenbankabfrage schreiben kann. Strukturierte Suchen sollen die Vorteile beider Vorgehensweisen kombinieren. Die Struktur der Daten soll a priori nicht bekannt sein müssen, aber trotzdem sollen die Suchergebnisse vollkommen präzise sein.

4.5. Lexical Search

TODO

4.6. Semantic Search

Eine Semantische Suche arbeitet nicht anhand von Keywords, sondern versucht die Bedeutung der Nutzereingabe zu verstehen und anhand dessen die passenden Dokumente zu suchen. Dazu versucht die Suchmaschine ebenfalls die Bedeutung von Dokumenten zu verstehen, damit die Bedeutung des Dokuments mit der Bedeutung der Nutzereingabe gematcht werden kann. Um eine semantische Suche zu implementieren, werden die Technologien von Transformern und Vektordatenbanken verwendet. Ein Transformer bekommt als Input eine große Menge an Text und mappt die einzelnen Wörter auf einen Vektor einer beliebigen Länge. Der Vektor, der am Ende herauskommt, beschreibt die Position des Wortes in einem n-dimensionalen Raum. Der Vektor beschreibt gewissermaßen, wie stark ein Wort in eine abstrakte Kategorie einzuordnen ist. Jeder Wert im Vektor entspricht einer Kategorie. Mithilfe der Vektoren können verschiedene Wörter hinsichtlich ihrer Ähnlichkeit analysiert werden. Ähnliche Wörter haben eine große räumliche Nähe, während zwei Wörter, die in vollkommen unterschiedlichen Kontexten verwendet werden eine sehr große Distanz im Raum besitzen. Nehmen wir für ein Beispiel einen dreidimensionalen Raum an. Die X-Achse ist beschriftet mit dem Wort „Tier“, die Y-Achse ist beschriftet mit dem Wort „Computer“ und die Z-Achse ist beschriftet mit dem Wort „Mensch“. Nun geben wir einem Transformer das Wort „Katze“, und der Transformer berechnet einen dreidimensionalen Vektor, welcher das Wort „Katze“ im Raum positioniert. Weil eine Katze ein Tier ist, ist der X-Wert des Vektors eins. Der Wert eins bedeutet, dass das Wort vollständig zu dieser Kategorie gehört. Da eine Katze überhaupt nichts mit einem Computer zu tun hat, ist der Y-Wert des Vektors 0. Nun ist eine Katze zwar kein Mensch, aber eine Katze ist ein Haustier von Menschen. Es ist denkbar, dass die Wörter Katze und Mensch oft im gleichen Kontext verwendet werden, sodass der Wert bei 0,3 liegen könnte. Damit der Transformer einen Vektor berechnen kann, braucht er eine Menge Daten. Diese Daten erhält er aus vielen Texten. Werden zwei Wörter oft im gleichen Text genannt oder kommen zwei Wörter in vielen Texten sehr nahe beieinander vor, dann geht der Transformer davon aus, dass die beiden Wörter ähnlich sind, und berechnet ähnliche Vektoren. Zuvor müssen die Texte allerdings bereitgestellt werden. Dazu kann beispielsweise das Internet gecrawlt werden. Die Ergebnisse des Transformers werden in einer Vektordatenbank gespeichert. Eine Vektordatenbank ist eine Datenbank, welche Vector Embeddings, also ein Objekt als Key und dessen Vektor als Value speichert. Bei dem Objekt kann es sich um Wörter handeln, dann wird auch von Word Embeddings gesprochen. Es können aber auch Daten anderer Daten, wie Bilder, Videos oder Audio gespeichert werden. Der Zweck von Vektordatenbanken ist es, Daten nicht einfach linear zu speichern, sondern in einem Raum. Die Distanz zwischen zwei Einträgen in diesem Raum beschreibt dessen Ähnlichkeit. Genau diese Informationen machen sich semantische

Suchen zu Nutze.

5. Vergleich der Suchfunktionen

6. Erläuterung des Ergebnisses

7. Implementierung

Die Architektur von Suchmaschinen besteht aus drei Komponenten. Aus dem Crawling, der Indexierung und der Suchfunktion selbst. Das Crawling ist zuständig für das Finden von Websites. Die Indizierung ist zuständig für das optimale Speichern der Informationen der Websites, und die Suche ist zuständig für das Verstehen der Nutzeranfrage und die Abfrage der relevantesten Informationen aus dem Index, sowie dessen Verarbeitung und Darstellung. Im Folgenden wird der Begriff Dokument verwendet, um die Dateien zu beschreiben, welche durch einen Crawler gesucht und durch den Index verarbeitet werden. Unter Dokumenten können hierbei auch eine Website verstanden, welche durch einen Webcrawler durchsucht werden.

7.1. Crawling

Bei der Implementierung eines Systems für eine Suchfunktion benötigt das System zunächst einen Datensatz von Dokumenten, welche überhaupt grundsätzlich über die Suchfunktion gefunden werden können. Dieser wird mithilfe eines Crawlers aufgebaut. Ein Crawler ist ein Algorithmus, welcher ein Dokument als Startpunkt bekommt, und anhand dessen neue Dokumente findet. Der Algorithmus analysiert dazu das Dokument auf Links, welchen der Algorithmus anschließend folgt. Die neuen Dokumente werden durch den Index verarbeitet und wiederum auf neue Links analysiert. Dieses Verfahren kann beliebig lange und beliebig rekursiv durchlaufen werden, um den Index zu erweitern. Neben dem Crawling können Indizes befüllt werden, indem eine Liste von Dokumenten übergeben werden, welche dem Index hinzugefügt werden sollen.

7.2. Indizierung

Bei der Indexierung werden Wörter und Tokens mit Dokumenten assoziiert. Dazu werden Wörter aus gecrawlten Dokumenten extrahiert und in die Datenbank geschrieben. Den Dokumenten werden IDs zugeordnet und diese IDs werden den Wörtern zugeordnet. Dem Index werden nun weitere Informationen hinzugefügt, wie die Wortfrequenz. Die Wortfrequenz gibt an, wie oft ein Wort in einem Dokument vorkommt. Es wird auch gespeichert, an welchen Stelle des Dokuments das Wort vorkommt, und auch in wie vielen Dokumenten ein Wort vorkommt. Diese Art der Indizierung wird auch als invertierter Index bezeichnet, weil den Wörtern bzw. Tokens die Dokumente zugeordnet werden, und nicht umgekehrt. Wenn der Nutzer nun ein Keyword in die Suche eingibt, dann sind diese Keywords oft bereits im Index vorhanden, sodass die Dokumente, welche diese Keywords bein-

halten einfach dem Index entnommen werden können. Aufgabe der Suche ist es anschließend die Ergebnisse aufzubereiten.

Volltext-Indizierung

Bei der Indizierung der Wörter besteht die Problematik, dass gleiche Wörter in unterschiedlichen Formen existieren können. So stammen „Heizung“ und „heizen“ beide von dem gleichen Wortstamm „heiz“ ab. Um bei der Indizierung Speicherplatz zu sparen, können Wörter auf diesen Wortstamm reduziert werden, damit sie als ein einziges Wort betrachtet werden können. Die Bildung des Wortstamms wird auch als Stemming bezeichnet. Beim Stemming kann es jedoch zu Overstemming und Understemming kommen. Overstemming bedeutet, dass zwei Wörter, die eigentlich nichts miteinander zu tun haben, also nicht semantisch gleich sind, den gleichen Wortstamm besitzen und als ein Wort betrachtet werden. Ein Beispiel hierfür sind die Wörter „Wand“ und „wandere“, wie in „ich wandere“. Beide besitzen den Wortstamm „wand“ und werden entsprechend als ein Wort betrachtet. Understemming bedeutet, dass zwei Wörter, die eigentlich etwas miteinander zu tun haben, also semantisch gleich sind, nicht den gleichen Wortstamm besitzen und dadurch als zwei verschiedene Wörter betrachtet werden. Ein Beispiel hierfür sind die Wörter „absorbieren“ und „Absorption“, welche die Wortstämme „absorb“ und „absorp“ besitzen. Es gibt Techniken zur Vermeidung solcher Probleme, wie der Einsatz vollständiger morphologischer Analysekomponenten. Hierauf soll aber nicht weiter eingegangen werden. Zur Implementierung eines Volltext-Index werden Dokumente und Wörter in einer $m \times n$ Matrix angeordnet, wobei m die Anzahl der Dokumente ist und n die Anzahl der Wörter. Die Werte in dieser Matrix werden anhand einer ausgewählten Metrik bestimmt. Eine oft verwendete Metrik ist das Verhältnis der Wortfrequenz mit der invertierten Dokumentfrequenz. Die Wortfrequenz gibt dabei an, wie häufig das in dem Dokument vorkommt. Die Dokumentfrequenz gibt an, in wie vielen Dokumente ein Wort vorkommt. Das Verhältnis gibt damit an, wie charakteristisch das Wort für ein bestimmtes Dokument ist. Wenn das Wort charakteristisch für ein Dokument ist, dann kommt es in diesem Dokument häufig vor, aber in anderen Dokumenten nur selten. Wenn das Wort nicht charakteristisch für das Dokument ist, dann kommt es in anderen Dokumenten genauso häufig oder häufiger vor als in diesem Dokument. Die Metrik wird auch als tf-idf-Wert bezeichnet. TODO Rechnung besser verstehen Wir können uns nun einen m -dimensionalen Raum vorstellen, in dem jedes Dokument eine Dimension darstellt. Jedes Dokument liegt räumlich auf der Achse der eigenen Dimension. Wenn der Nutzer nun Die Matrix lässt sich konzeptionell so verstehen, dass sie aus n Merkmalsvektoren besteht. Verwenden wir die eben beschriebene Metrik, dann gibt jeder Merkmalsvektor eine Gewichtung an, wie charakteristisch ein Wort für die verschiedenen m Dokumente ist. Nun kann der Nutzer Keywords in die Suche eingeben. Diese Keywords

7.3. Suffix-Trees

TODO

7.4. N-Gramm

Ein N-Gramm ist das Ergebnis der Spaltung eines Textes in N Fragmente. Fragmente können dabei Buchstaben, Wörter, Phoneme, Morpheme etc. sein. N-Gramme können bei der Indizierung verwendet werden und werden auch in Algorithmen von Stemming und Information Retrieval verwendet, außerdem werden durch N-Gramme Rechtschreibprüfungen oder die Suche nach ähnlichen Wörtern ermöglicht. Besteht ein Text aus einem Fragment, dann wird von einem Monogramm geredet. Besteht es aus zwei, wird es Bigramm genannt. Um Algorithmen wie eine Rechtschreibprüfung zu ermöglichen, wird neben N-Grammen auch Ähnlichkeitsmaß benötigt, welches beschreibt, wie ähnlich sich zwei Terme sind. Das Wort Term ist an dieser Stelle synonym mit Wort zu verstehen. Der Dice-Algorithmus ist ein Ähnlichkeitsmaß für Terme. Er zerlegt zwei Terme in dessen N-Gramme und bestimmt anhand dieser die Ähnlichkeit der beiden Terme. Der Dice-Algorithmus lautet wie folgt:

TODO Equation

Nehmen wir beispielsweise die beiden Terme $a = \text{„Wort“}$ und $b = \text{„Wirt“}$. Verwenden wir in diesem Beispiel Bigramme, dann ergeben sich für a folgende Bigramme: „\$W“, „Wo“, „or“, „rt“, „t\$“. Für b ergeben sich: „\$W“, „Wi“, „ir“, „rt“, „t\$“. Die Schnittmenge der beiden Mengen, also die Bigramme, welche sowohl in a als auch in b vorhanden sind, lauten „\$W“, „rt“, „t\$“. Es sind also drei Stück. Das bedeutet der Zähler der Funktion ergibt $2 \cdot 3$ also 6. Die Anzahl der Bigramme in a und b sind jeweils 5, also ist der Nenner $5 + 5$, also 10. Dann ist das Ähnlichkeitsmaß der beiden Wörter bei der Verwendung von Bigrammen $6/10$ (60%). Bei der Verwendung von Trigrammen besitzt a „\$\$W“, „\$Wo“, „Wor“, „ort“, „rt\$“, „t\$\$“ und b „\$\$W“, „\$Wi“, „Wir“, „irt“, „rt\$, „t\$\$“. Es gibt drei gemeinsame Trigramme. Das Ergebnis ist $(2 \cdot 3)/(6 + 6)$ also 50%. An diesem Beispiel lässt sich zeigen, dass sich das Ergebnis des Ähnlichkeitsmaß verändert, wenn ein anderes N-Gramm verwendet wird.

7.5. Information Extraction

Information Extraction ist der Prozess des Extrahierens von Informationen aus Dokumenten. Dazu müssen zunächst die Dokumente gefunden werden, welche die passenden Informationen enthalten. Dieser Schritt wird Information Retrieval genannt. Das Extrahieren von Informationen mit einer Vielzahl von Algorithmen und erfolgt in mehreren Schritten. Der erste Schritt von Information Extraction ist das Einteilen des Textes in Sätze. Dieser Schritt wird Sentence Segmentation genannt. Anschließend werden aus jedem Satz die einzelnen Wörter extrahiert (Word Tokenization) und kategorisiert als Nomen, Verb, Objekt, Pronomen etc.

(Part-of-Speech Tagging). Für das Part-of-Speech Tagging gibt es zwei Implementierungsansätze, rule-based anhand von Grammatikregeln und statistic-based. Es folgt Syntactic Parsing, also das Generieren eines Syntaxbaumes, welcher den Text repräsentiert. Zuletzt wird mithilfe von Coreference Resolution identifiziert, welche Stellen im Text sich auf die gleichen Entitäten beziehen. Ein Beispiel für Coreference Resolution ist, dass ein System versteht, dass mit „Angela Merkel“ und „Merkel“ oder auch „A. Merkel“ die gleiche Person gemeint ist. Mithilfe dieser Schritte können Key Phrase Extraction, Named Entity Recognition, Entity Disambiguation, Relation Extraction und Event Extraction implementiert werden. Key Phrase Extraction ist das Identifizieren von Schlüsselwörtern im Text, welche für diesen Text charakteristisch sind und welche den Text klassifizieren. Ein Rezept für das Backen von Schokoladenkeksen könnte beispielsweise mithilfe von Schlüsselwörtern, wie „Backen“, „Kekse“, „Schokolade“ beschrieben werden. Named Entity Recognition ist das Identifizieren von Personen, Orten und Datumsangaben. Entity Disambiguation ist das Auseinanderhalten von Entitäten, welche die gleichen oder ähnliche Wörter besitzen. Unter dem englischen Wort „apple“ lässt sich nicht nur ein tatsächlicher Apfel verstehen, sondern es könnte sich auch um das Unternehmen apple handeln. Welche Bedeutung des Wortes die korrekte ist, erschließt sich aus dem Kontext. Das ist die Aufgabe von Entity Disambiguation.

TODO Image

Teilbereiche von Informationsextraktion sind Named Entity Recognition, Named Entity Linking, Relation Extraction, Knowledge Base Reasoning. Informationsextraktion ist für viele Anwendungsfälle der erste Schritt in einer größeren Pipeline. Das könnte z.B. ein Chatbot sein oder ein Übersetzer. Named Entity Recognition ist die Erkennung von Eigennamen. Named Entity Linking ist der Prozess, eine bestimmte Entität eine einzigartige Identität zu geben. Die Entität wird auf eine Target Knowledge Base gemappt, welche weitere Informationen über ebendiese Entität enthält. Relation Extraction erkennt Beziehung zwischen Entities. Die Beziehung kann durch ein Subjekt Prädikat Objekt Triple repräsentiert werden. Abgrenzung von Information Extraction und Information Retrieval. Information Retrieval selektiert relevante Dokumente. Information Extraction extrahiert Informationen aus einem gegebenen Dokument. Die Klassifikation von Texten wird auch als Topic Modeling bezeichnet. Es wird die Häufigkeit von Wörtern aus bestimmten Kategorien bestimmt und damit ein Thema zugeordnet. Dieses Verfahren könnte zur Ermittlung von Labels verwendet werden. Die Labels gehen dabei über die Inhalte des Textes hinaus. Ein Algorithmus zum Topic Modeling ist Explicit Semantic Analysis (ESA). Language Modelling ist ein Task von NLP, welcher es ermöglicht Texte zu übersetzen, Spellchecking, Spracherkennungen und Handschrifterkennung zu implementieren.

TODO Image

8. Zusammenfassung und Ausblick

8.1. Zusammenfassung

TODO

8.2. Ausblick

TODO

Anhang

A. Anhang

A.1. TODO

TODO

Eidesstattliche Erklärung

Hiermit versichere ich, dass ich die vorliegende Arbeit ohne Hilfe Dritter und nur mit den angegebenen Quellen und Hilfsmitteln angefertigt habe. Ich habe alle Stellen, die ich aus den Quellen wörtlich oder inhaltlich entnommen habe, als solche kenntlich gemacht. Diese Arbeit hat in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen.

Essen, den 19. April 2023
